

专利申请技术交底书(模板)

基 本 信 息			
类 型	<input checked="" type="checkbox"/> 发明 <input type="checkbox"/> 实用新型 <input type="checkbox"/> 外观设计 <input type="checkbox"/> PCT		
名 称	基于深度神经网络的乳腺癌超声图像辅助诊断方法		
立案日期			
第一联系人		单位:	电话:
		身份:	邮箱:
第二联系人	姓名:	单位:	电话:
		身份:	邮箱:
第三联系人	姓名:	单位:	电话:
		身份:	邮箱:
专 利 内 容			
<p>1、技术领域:</p> <p>本发明涉及智能医疗领域，具体是一种基于深度神经网络的乳腺癌超声图像辅助诊断方法。</p>			
<p>2、背景技术:</p> <p>乳腺癌超声图像辅助诊断方法可以为医疗人员提供高准确性的辅助诊断参考。辅助诊断方法通过对乳腺超声图像进行分析，能够识别、标注图像中乳腺结节区域，并判断结节类型，从而为医疗人员提供即时、高鲁棒性、高精度、可视化的辅助诊断参考。与此同时，辅助诊断方法能对人眼难以发现、难以辨别的乳腺癌进行判断和标注，提高乳腺癌检出率、准确性，降低医疗漏诊误诊事故，提高医疗质量。</p>			
<p>3、发明内容:</p> <p>1) 本发明创造所要解决的技术问题:</p> <p>本发明针对现有技术的不足，提出一种基于深度神经网络的乳腺癌超声图像辅助诊断方法;</p> <p>1. 现基于机器学习的乳腺癌超声图像的结节图像分割和结节图像分类是两个独立任务，对应两个端到端的深度神经网络模型，由于训练目标和模型结构的不同，两个神经网络模型学习所学习的样本分布会普遍存在差异，导致两个模型预测出矛盾的结果。例如，</p>			

专利申请技术交底书(模板)

对于同一个乳腺超声图像，在图像分割网络中预测没有结节，而在分类任务中预测有结节；

2. 现有的图像分割神经网络和图像分类神经网络的特征提取能力不足，以及切割边缘不平滑。提出一种基于注意力机制和平滑模块的图像分割和图像分类神经网络，在不显著增加模型参数的情况，显著提高模型的特征提取能力和预测结果边缘的平滑。

2) 解决其技术问题采用的技术方案（可以结合图纸来描述）

S1、搭建结节图像分割网络

基于卷积编码器和解码器架构的深度卷积神经网络，在编码器的所有输出中以残差结构引入基于通道和空间注意力机制模块，利用残差结构使得注意力机制模块的输出不会使得模型效果更差，进而提高模型提取关键特征的能力；同时在网络尾部嵌入本文设计的卷积平滑模块，平滑预测区域边缘，同时去除不合理的噪点；

S2、搭建结节类型分类网络

以 S1 结节图像分割网络的模型结构为基础微调模型结构，在网络模型中额外增加基于全连接的分类器，分类器的输入由模型编码器的部分输出和解码器输出构成，进而计算出无结节、良性结节和恶性结节的概率，以最高的概率作为最终的分类结果；

S3、搭建结节类型预测融合网络

构建深度神经网络，输入包括 S1 分割网络的输出（结节预测图）和 S2 分类网络的输出（类型概率预测），将 S2 的结节类型概率预测向量向 S1 模型的预测融合，形成并输出新的结节类型概率预测向量。

4、与现有技术相比具有的有益效果：

1. 提高模型特征提取能力：通过在编码器和解码器之间加入若干残差结构和注意力模块，不显著增加网络参数量，与此同时同时大幅度增加网络的特征提取能力；
2. 分割效果更为合理：通过加入特定参数的卷积模块，能大幅度平滑分割区域的边缘，同时去除不合理的小预测区域；
3. 分类预测更为精确：类型预测类型融合网络能够融合分割网络和分类网络的类别预测，给出更为精准的类型预测向量；

5、附图及其说明：

图 1 是本发明的流程示意图：

专利申请技术交底书(模板)

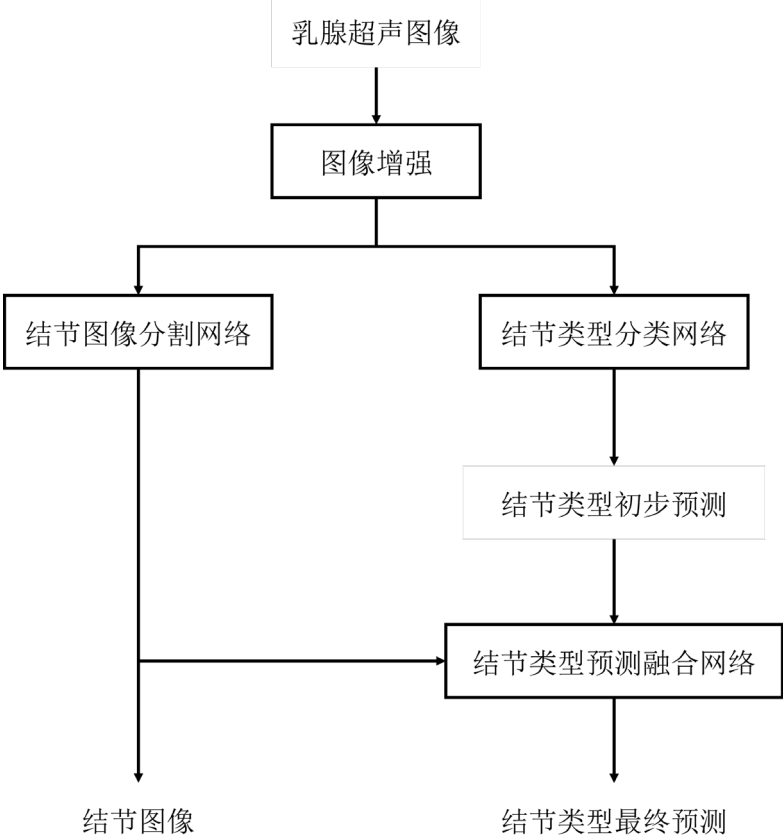


图 1

图 2 是结节图像分割网络的结构示意图：

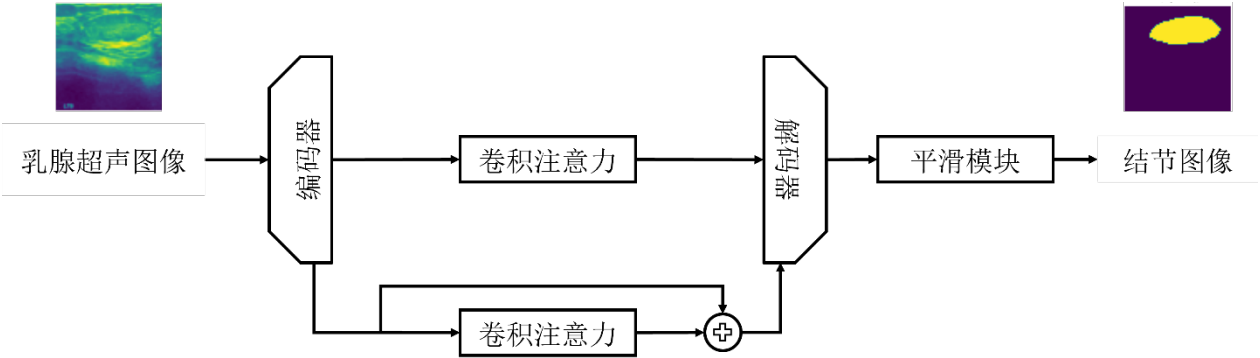


图 2

图 3 是结节类型分类网络的结构示意图：

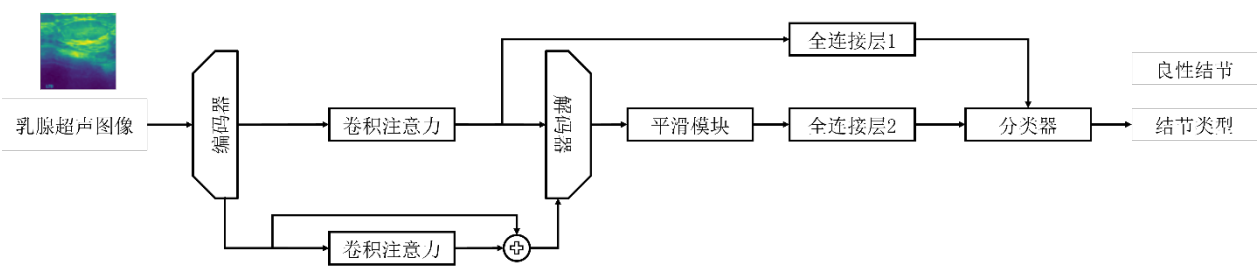


图 3

图 4 是结节类型预测融合网络的结构示意图：

专利申请技术交底书(模板)

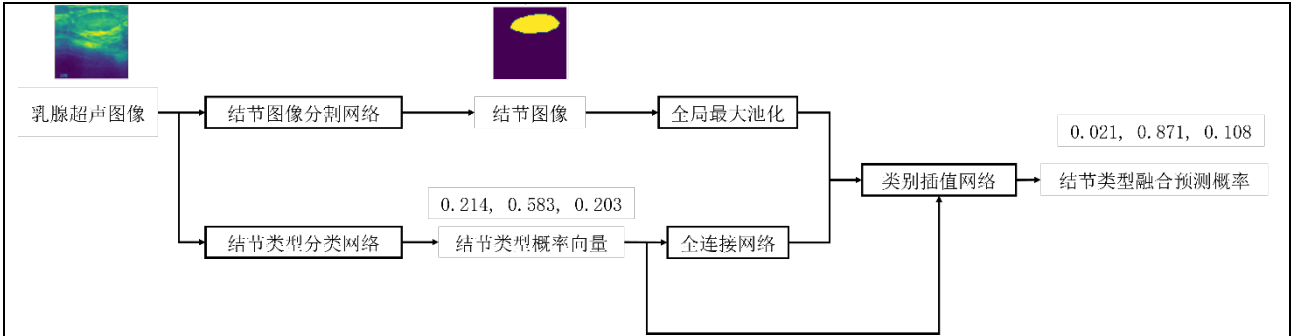


图 4

图 5 是乳腺超声图像数据集的其中一部分乳腺超声图像以及对应的结节图像：

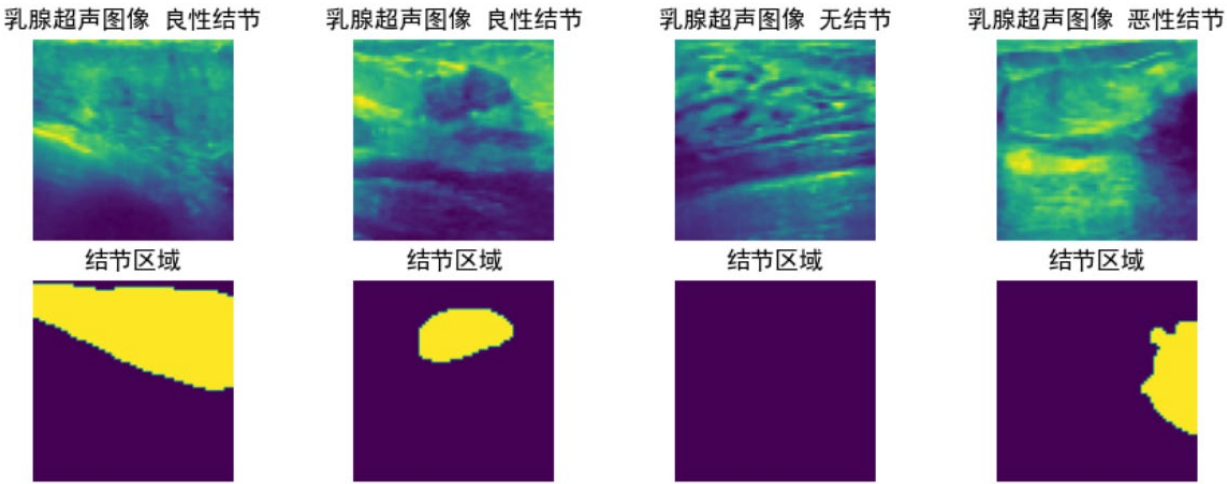


图 5

图 6 是图 1 的运行效果展示图，由上至下分别是乳腺结节超声图片、对应的结节分割网络的结节图像诊断结果（结节区域）、结节分类网络的结节类型诊断结果（结节类型）和结节类型预测融合网络的诊断结果（结节类型）：

专利申请技术交底书(模板)




图 6

6、具体实施方式：（此部分举例说明技术方案是怎样的，有那些具体的实施方案）

作为一种具体的实施方式，参见图 1，基于深度神经网络的乳腺癌超声图像辅助诊断方法中包括三个深度卷积神经网络，需要对这三个深度卷积神经网络进行设计和训练，以最终实现图 1 的工作流程。

因此，在此阐述方法运作前的准备流程以及方法的实际运作流程：

S1、乳腺超声图像数据集

本方法采集的图像来自于美国 Baheya 医院制作的公开数据集，使用 LOGIQ E9 超声系统和 LOGIQ E9 敏捷超声系统进行乳腺超声图像采集，超声图像分辨率为 1280*1024，采集且筛选为良性结节、恶性结节（乳腺癌）和无结节共 780 张超声图像。该数据集乳腺结节超声图像对应的结节图像同样由该医院制作。部分乳腺超声图像和对应结节图像如图 4 所示。

S2、图像增强

对训练集中的超声图像施加多种常规图像处理，包括图像尺寸裁剪、图像中心裁剪、数值归一化；每次读取该超声图像作为训练图像时，则会施加随机参数的亮度扰

专利申请技术交底书(模板)

动、色度扰动、施加高斯噪声以及随机像素擦除等扰动，提高训练集的多样性以及重复利用率，避免模型训练的过拟合。

而测试集的超声图像处理使用包括：图像尺寸裁剪、图像中心裁剪和数值归一化。

S3、结节图像分割网络模型的设计与训练

S31、结节图像分割网络模型的设计

S311、编码器和解码器

编码器和解码器是一对相反的操作，均由卷积层组成。编码器由多个卷积层和最大池化层组成，进入编码器的原始乳腺超声图像的特征图大小逐渐缩小，编码器逐渐获取不同大小的特征图。解码器则由多个反卷积层组成，进入解码器的特征图将逐步放大，特征图将逐步复原到原始乳腺超声图像的大小，解码器的输出与原始乳腺超声图像的每一个像素一一对应，即为结节像素。由结节像素组成的区域为结节区域。

S312、引入卷积注意力模块

本文在解码器的所有输入数据前均加入卷积注意力模块。而除了编码器的最小特征图仅加入卷积注意力模块，其他输出均采用残差结构包裹的卷积注意力模块。在编码器的最小特征图后加入卷积注意力模块，是为了迫使编码器提取计算不同通道和空间的特征，提取样本到最重要的特征集合。而编码器的其他输出采用残差结构包裹的卷积注意力模块，是利用了残差结构的优良性质：假设卷积注意力模块的提取特征有害于网络计算，在求导上为很小的数值，在残差结构的作用下，卷积注意力模块的系数将很低，同时之前的网络层将不会因此调整参数：

$$x = x + Attention(x)$$

因此加入了残差结构的卷积注意力模块对模型不会起到负面作用。而考虑到卷积注意力层能提取不同通道和空间的特征，因此加入注意力模块的网络的提升是正面的。

S313、设计卷积平滑模块

目前主流基于编码器和解码器的架构，以解码器的输出为最终输出，然而解码器的输出中，存在着不合理性。首先，解码器的输出是由解码器逐步复原特征图计算得来，小特征图的不合理特征和噪点将被不断放大，最终输出为多个小直径的结节。其次，解码器的输出图像的结节区域边缘不平滑，结节区域边缘锯齿状明显，结节图形过度畸形和不规则，不符合实际情况。

本文提出基于卷积层堆叠的过滤平滑模块，将解决该问题：

专利申请技术交底书(模板)

层	参数		
	输入通道	输出通道	卷积核大小
卷积	1	2	5
卷积	2	1	5
卷积	1	2	3
卷积	2	1	3

卷积层在每次输出通道为 2 时，再映射回通道数为 1 时，网络的两个特征图中响应小的特征图被去除、响应最大的特征图被保留，也即是过滤不合理边缘和噪点的特征图。经过两次的不合理特征过滤，此时的分割结果将是平滑且少噪点的。

S32、结节图像分割网络模型的设计

采用 Tversky 损失函数，进行模型训练，促进模型在数量不平衡的学习样本中获得更高的泛化和更好的性能，Tversky 损失函数如下：

$$\frac{\sum_{i=1}^N p_{0i} g_{0i}}{\sum_{i=1}^N p_{0i} g_{0i} + \alpha \sum_{i=1}^N p_{0i} g_{1i} + \beta \sum_{i=1}^N p_{1i} g_{0i}}$$

其中， g_{0i} 代表真实结节图像的第*i*个像素是肿瘤则为 1，否则为 0， g_{1i} 代表真实结节图像的第*i*个像素是肿瘤则为 0，否则为 1； p_{0i} 代表第*i*个像素是预测为肿瘤的概率， p_{1i} 则反之。超参数 α 、 β 取为 0.5。

初始化图 2 的结节图像分割网络模型参数，在 pytorch2.0 神经网络框架进行训练。在模型训练过程，若损失函数不下降则将学习率乘以 0.1 继续训练，直至学习率小于等于 2e-8，停止模型训练。完成结节图像分割网络模型的训练。

S4、结节类型分类网络模型的设计与训练

S41、结节类型分类网络模型的设计

在 S3 结节图像分割网络模型的基础上，设计分类器。

S411、结节类型分类网络的分类器设计

为了更加准确的计算每个结节类别（无结节、良性结节和恶性结节）的概率，需要引入两个输入进行预测，一个输入代表网络最小特征集合，也即是最难提取结节复杂特征的集合，蕴含良性结节和恶性结节的抽象特征，来自图 3 中无残差结构的卷积注意力模块的输出。

专利申请技术交底书(模板)

根据图 3，分类网络分类器的输入包括解码器输出和一个卷积注意力模块计算后的输出，分别设为 x_1 和 x_2 ：

$$y_1 = x_1 * w_1 + b_1$$

$$y_2 = x_2 * w_2 + b_2$$

其中 w_1 和 b_1 为一个线性全连接网络，提取 x_1 的特征，并输出形状为(1,1)的标量，记作 y_1 。对于 x_2 同理， w_2 和 b_2 为另一个线性全连接网络，并输出形状为(1,2)的向量，记作 y_2 。

合并行向量为：

$$z = y_1, y_2$$

z 向量的形状为(1,3)，分类器的结果则为：

$$Y = \text{Softmax}(z) = \frac{\exp(z_i)}{\sum_i z_i}$$

Y 向量则为结节类型概率的预测。

S42、结节类型分类网络模型的训练

采用交叉熵损失函数，公式为：

$$L(x, \text{class}) = -x[\text{class}] + \log\left(\sum_i e^{x[i]}\right)$$

其中， x 是预测类别概率向量， class 则是预测向量对应的真实类别向量。

初始化图 3 的结节类型分类网络模型参数，在 S3 同样的软件、硬件平台上进行向量，且使用同样的学习率下降策略，直到学习率小于等于 $2e-8$ 的时候停止训练，完成结节类型分类网络模型的训练。

S5、结节类型预测融合网络模型的设计与训练

结节类型预测融合网络（下称类型融合网络）的目的，在于结合结节图像分割网络的输出和结节类型分类网络的输出，来求得更接近于真实的结节类型分布 $P^* = (p_1^*, p_2^*, p_3^*)$ ，求得更合理的结节类型分类。

S51、结节类型预测融合网络模型的设计

S511、结节类型预测融合网络模型的总体设计

按照 S3 结节图像分割网络的设计和训练，考虑一个已训练结束的结节图像分割网络，其输出、结节图像显示每个像素的结节概率，不妨假设结节图像中隐含结节类型分布 $P^{seg} = (p_1^{seg}, p_2^{seg}, p_3^{seg})$ ；已训练的结节类型分类网络的结节类型分布 $P^{class} =$

专利申请技术交底书(模板)

$(p_1^{class}, p_2^{class}, p_3^{class})$ ，由于分割网络和分类网络的结构、损失函数、随机数和收敛方向的不同，显然应该存在：

$$p^{seg} \neq p^{class} \neq P^*$$

假如有一个函数 f^* 使得：

$$f^*(p^{seg}, p^{class}) = P^*$$

下文描述设计的 f 来逼近 f^* ，以逼近 P^* ：

$$f(p^{seg}, p^{class}) \rightarrow f^*(p^{seg}, p^{class}) = P^*$$

S512、 P^{seg} 的估计

在结节分割网络的输出中可以显然知道，每个像素点值是[0,1]的结节概率，但是不包含良性结节和恶性结节（癌）的概率，因此可以认为在输入为结节图像 $Mask$ 时存在一个非线性函数 h ：

$$P_1^{seg} = h(Mask) = MLP(Mask)$$

其中 h 由多层感知机（Multi-Layer Perceptron, MLP）进行拟合和估计。而考虑到良性结节和恶性结节在 $Mask$ 上是难以分辨的，因此不进行估计。

S513、 P^{class} 的良性结节和恶性结节的特征提取

首先明确结节分类网络的 P_2^{class} 和 P_3^{class} 比 P_2^{seg} 和 P_3^{seg} 更加接近真实的良、恶性结节类型分布，已知结节分类网络的输出为 $class$ ，考虑提取出 P^{class} 的良、恶性结节的分布特征：

$$Feature(\text{良性结节} | \text{结节}, class)、Feature(\text{恶性结节} | \text{结节}, class)$$

进行使用多层感知机拟合和估计 $Feature$ 值：

$$F_1, F_2 = MLP(class)$$

添加一个约束：

$$F_1 + F_2 = 1$$

因此：

$$F_1, F_2 = Softmax(MLP(class))$$

S514、类别预测

专利申请技术交底书(模板)

考虑以下概率公式：

$$\begin{aligned} P^*(\text{结节}) &= P^*(\text{良性结节}, \text{结节}) + P^*(\text{恶性结节}, \text{结节}) \\ &= P^*(\text{良性结节} \mid \text{结节}) \times P^*(\text{结节}) + P^*(\text{恶性结节} \mid \text{结节}) \times P^*(\text{结节}) \end{aligned}$$

那么：

$$\begin{aligned} P^* &= \text{Softmax}(1 - P^*(\text{结节}), \\ &P^*(\text{良性结节} \mid \text{结节}) \times P^*(\text{结节}), P^*(\text{恶性结节} \mid \text{结节}) \times P^*(\text{结节})) \end{aligned}$$

形式类似的，在此构造一个 P' ：

$$P' = \text{Softmax}(1 - P_1^{seg}, F_1 \times P_1^{seg}, F_2 \times P_2^{seg})$$

满足 $\sum P' = 1$ 。该 P' 即是结节类型预测融合网络的输出。

S52、结节类型预测融合网络的训练

同 S42，对网络进行训练。

S6、训练效果测试

对本方法进行使用测试，在测试集中进行测试。方法使用效果如图 6 所示。

图 6 第二列的最后两行文字分别显示了结节类型分类网络和结节类型预测融合网络的结节类型预测。在分类网络分类错误（显示良性结节）的情况下，结节类型预测融合网络额外参考了结节图像（显示无结节），进行了正确的结节分类预测（无结节）。显示了

本方法实现了对乳腺超声图像的结节类型准确预测和结节图像预测，为医疗人员诊断乳腺癌提供了便利。